

NHẬP MÔN HỌC MÁY


Học máy · Deep Learning · Generative AI

TS. Cao Tiến Dũng



**FPT SCHOOL OF BUSINESS
& TECHNOLOGY**

AI, Học máy & Học sâu




- **Trí tuệ nhân tạo (AI):** lĩnh vực rộng nhất — máy móc thực hiện các tác vụ cần trí thông minh.
- **Học máy (ML):** tập con của AI — máy học từ dữ liệu thay vì được lập trình tường minh.
- **Học sâu (Deep Learning):** tập con của ML — dùng mạng nơ-ron nhiều lớp; nền tảng của GenAI và LLM ngày nay.

Học máy là gì?

Wikipedia:

Học máy là một nhánh của khoa học máy tính, ***“trao cho máy tính khả năng học mà không cần được lập trình một cách tường minh”***.



01

Phân loại Học máy

Types of Machine Learning

Phân loại Học máy

Có giám sát (Supervised)

Huấn luyện trên dữ liệu đã biết kết quả (có nhãn).

Không giám sát (Unsupervised)

Huấn luyện trên dữ liệu chưa biết kết quả (không nhãn).

Bán giám sát (Semi-Supervised)

Kết hợp một ít dữ liệu có nhãn với rất nhiều dữ liệu không nhãn.

Tăng cường (Reinforcement)

Huấn luyện qua hệ thống thưởng và phạt.

Phân loại ML: Ví dụ thực tế

Có giám sát

Ví von: *Ví như học với đáp án có sẵn.*

Ví dụ: Lọc thư rác, dự đoán giá nhà, phát hiện ung thư

Không giám sát

Ví von: *Như phân loại một đồng đồ vật mà không có hướng dẫn.*

Ví dụ: Phân khúc khách hàng, mô hình chủ đề, phát hiện bất thường

Bán giám sát

Ví von: *Học ngoại ngữ với 10 câu dịch + 10.000 câu bản ngữ.*

Ví dụ: Gom nhóm khuôn mặt trong Google Photos, gán nhãn ảnh y khoa

Tăng cường

Ví von: *Như huấn luyện chó bằng phần thưởng và uốn nắn.*

Ví dụ: AlphaGo, xe tự lái, robot di chuyển

Học có giám sát (Supervised)

- Huấn luyện thuật toán bằng các điểm dữ liệu đã biết kết quả (có nhãn Y).
- Hai bài toán chính:

#	X	Y
0	X0	Y0
1	X1	Y1
2	X2	Y2

Phân loại (Classification)

- Dự đoán một HẠNG MỤC (đầu ra rời rạc).
- Ví dụ: thư rác / không rác, mèo / chó.

Hồi quy (Regression)

- Dự đoán một SỐ (đầu ra liên tục).
- Ví dụ: giá nhà, nhiệt độ ngày mai.

Có giám sát: Phân loại vs Hồi quy

Phân loại — đoán HẠNG MỤC

- “Cái này thuộc loại nào?”
- Email → Rác / Không rác
- Ảnh X-quang → Ung thư / Khỏe
- Ảnh → Mèo / Chó / Chim
- **Ý chính:** vẽ ranh giới quyết định giữa các lớp.

Hồi quy — đoán SỐ

- “Bao nhiêu?”
- Diện tích nhà → 250.000 \$
- Số giờ học → GPA 3.7
- Hôm nay → Nhiệt độ ngày mai 34.5°C
- **Ý chính:** khớp một đường/đường cong qua dữ liệu.

Quy tắc: tập nhãn hữu hạn → Phân loại; giá trị số bất kỳ → Hồi quy

Biến mục tiêu vs Đặc trưng

- **Mục tiêu (Target):** cột cần dự đoán.
- **Đặc trưng (Features):** các thuộc tính dùng để dự đoán (những cột không phải mục tiêu).


dài đài	rộng đài	dài cánh	rộng cánh	Loài (mục tiêu)
6.7	3.1	4.7	1.5	versicolor
4.9	3.0	1.4	0.2	setosa
6.3	3.3	6.0	2.5	virginica
5.8	2.7	5.1	1.9	virginica

Ví dụ (1): Lọc thư rác

- **Mục tiêu:** dự đoán một email là thư rác hay không.
- **Dữ liệu:** email lịch sử đã gán nhãn rác / không rác.

Mục tiêu (Target): Rác / Không rác.

Đặc trưng (Features): nội dung, tiêu đề, thời gian gửi...




RÁC ?
KHÔNG RÁC ?

Ví dụ (2): Khung bao đối tượng

- **Mục tiêu:** dự đoán vị trí khung bao (bounding box) quanh một vật thể.
- **Dữ liệu:** ảnh kèm vị trí khung bao.

Mục tiêu (Target): tọa độ các góc của khung bao.

Đặc trưng (Features): các pixel của ảnh.



Học không giám sát (Unsupervised)

- Huấn luyện thuật toán bằng các điểm dữ liệu CHƯA biết kết quả (không nhãn).



Phân cụm

Clustering



Phát hiện bất thường

Anomaly Detection



Giảm chiều

Dimensionality Reduction



Biểu diễn thưa

Sparse Representation



Biểu diễn độc lập

Independent Representation

Không giám sát: Phân khúc khách hàng

- **Bối cảnh:** công ty TMĐT muốn hiểu khách hàng. Đầu vào: lịch sử mua, tần suất, chi tiêu trung bình — không nhãn. Mô hình tự gom nhóm theo hành vi tương tự.

Nhóm A

- Chi nhiều + Ít thường xuyên
- → Khách VIP / Cao cấp
- **Hành động:** Gửi ưu đãi truy cập sớm độc quyền

Nhóm B

- Chi ít + Rất thường xuyên
- → Khách trung thành sẵn giảm giá
- **Hành động:** Nổi bật mã giảm giá & deal hằng tuần

Nhóm C

- Chi vừa + Hiếm ghé
- → Có nguy cơ rời bỏ
- **Hành động:** Email kéo lại kèm ưu đãi

Học bán giám sát (Semi-Supervised)

- Huấn luyện với một LƯỢNG NHỎ dữ liệu có nhãn cùng một LƯỢNG LỚN dữ liệu không nhãn.

#	X	Y (nhãn)
0	X0	Y0
1	X1	<i>chưa biết</i>
2	X2	<i>chưa biết</i>
3	X3	Y3
4	X4	<i>chưa biết</i>
5	X5	<i>chưa biết</i>

Chỉ vài điểm có nhãn (Y0, Y3) — phần lớn còn lại chưa biết


Học tăng cường: Các bước thời gian

- Huấn luyện thuật toán bằng hệ thống THƯỞNG và PHẠT theo từng bước thời gian.

Bước	Trạng thái	Hành động	Phần thưởng
0	S0	A0	-1
1	S1	A1	0
2	S2	A2	0
3	S3	A3	0
4	S4	A4	0
5	S5	A5	+1

Tác nhân nhận thưởng/phạt theo thời gian; mục tiêu: tối đa hóa tổng phần thưởng

Học tăng cường: Vòng lặp Tác nhân – Môi trường



Mục tiêu: tối đa hóa TỔNG phần thưởng theo thời gian

- **Ví von:** dạy AI chơi Pac-Man. Ăn chấm: +10; va vào ma: -100; đi an toàn: 0.
- **Ý chính:** tối ưu cho TỔNG phần thưởng theo thời gian — “đau ngắn hạn” có thể đổi “lợi dài hạn”. Ví dụ thực tế: AlphaGo, cánh tay robot, làm mát trung tâm dữ liệu (Google DeepMind).

02

Thuật toán & Lựa chọn mô hình

Algorithms & Model Selection

Thuật toán cho Học có giám sát

- Hồi quy tuyến tính (Linear Regression)
- Hồi quy logistic (Logistic Regression)
- Cây quyết định (Decision Tree)
- Máy vector hỗ trợ (SVM)
- Naïve Bayes
- k-láng giềng gần nhất (kNN)
- Rừng ngẫu nhiên (Random Forest)
- Các thuật toán Gradient Boosting: GBM, XGBoost, LightGBM, CatBoost

Chọn thuật toán giám sát nào?

Thuật toán	Hình dung như...	Phù hợp khi...
Linear Regression	Vẽ một đường thẳng	Đầu ra là số liên tục
Logistic Regression	Quyết định bạn ở phía nào của đường	Phân loại nhị phân có/không
Cây quyết định	Trò chơi 20 câu hỏi	Cần quyết định giải thích được
SVM	Tìm khe rộng nhất giữa các lớp	Dữ liệu nhỏ, nhiều chiều
Naïve Bayes	Đếm tần suất từ	Phân loại văn bản, lọc thư rác
kNN	Bạn là ai tùy hàng xóm của bạn	Dữ liệu nhỏ, mẫu cục bộ quan trọng
Random Forest	100 cây quyết định cùng bỏ phiếu	Đa dụng, kháng nhiễu tốt
XGBoost	Sửa lỗi của mô hình trước đó	Dữ liệu bảng, các cuộc thi

Không có thuật toán “tốt nhất” tuyệt đối — bắt đầu đơn giản (Logistic) rồi nâng độ phức tạp khi cần

Thuật toán cho Học không giám sát

Phân cụm (Clustering)

- K-means
- MeanShift
- Phân cấp (Hierarchical)
- DBSCAN


Giảm chiều (Dimensionality Reduction)

- PCA — Phân tích thành phần chính
- *Chiếu dữ liệu nhiều chiều xuống ít chiều hơn, giữ lại phần lớn thông tin.*

Chọn mô hình nào? Những yếu tố cân nhắc

- Thời gian cần để huấn luyện
- Tốc độ đưa ra dự đoán
- Lượng dữ liệu cần thiết
- Loại dữ liệu
- Độ phức tạp của bài toán
- Khả năng giải bài toán phức tạp
- Xu hướng làm phức tạp hóa một bài toán đơn giản

Cách chọn đúng mô hình



03

Đánh giá mô hình

Model Evaluation

Độ đo đánh giá (Evaluation Metric)

- Có nhiều độ đo để đánh giá hiệu năng, ví dụ:

Độ chính xác (Accuracy)

- Dự đoán khớp với giá trị thật đến đâu.



Sai số toàn phương trung bình (MSE)

- Bình phương khoảng cách trung bình giữa dự đoán và giá trị thật.

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

⚠ Chọn sai độ đo có thể gây hiểu lầm hoặc không phản ánh đúng bài toán.

Khi độ đo đánh lừa ta

- Chọn sai độ đo có thể gây hiểu lầm hoặc không nắm được bài toán thực sự.
- Ví dụ: dùng Accuracy cho bài toán thư rác / không rác.
- **Nếu 99/100 email thực sự là rác**, thì một mô hình luôn dự đoán “rác” sẽ đạt 99% độ chính xác.
- **Hệ quả:** một email quan trọng có thể bị đẩy vào thư rác — dù chỉ số accuracy rất cao.

Độ đo: Độ chính xác (Accuracy)

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

- **Khi nào dùng:** Accuracy phù hợp với bài toán phân loại CÂN BẰNG, không bị lệch lớp (no class imbalance).

TP/TN/FP/FN: số ca dương/âm đúng và dương/âm sai (từ ma trận nhầm lẫn)

		Actual	
		Positive	Negative
Predicted	Positive	True Positive	False Positive
	Negative	False Negative	True Negative

Độ đo: Precision & Recall

$$Precision = \frac{TP}{TP + FP}$$

Precision (Độ chính xác dương)

- Dùng khi muốn RẤT CHẮC CHẮN về dự đoán dương của mình.
- Trong số bị gán cờ, bao nhiêu là thật?

$$Recall = \frac{TP}{TP + FN}$$


Recall (Độ bao phủ)

- Dùng khi muốn BẮT ĐƯỢC CÀNG NHIỀU ca dương càng tốt.
- Trong số ca dương thật, bắt được bao nhiêu?

Độ đo: F1-Score

$$F_1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$$

- **Khi nào dùng:** khi muốn mô hình tốt cả Precision LÃN Recall.
- *F1 là trung bình điều hòa (harmonic mean) — phạt nặng khi hai chỉ số lệch nhau nhiều.*




Độ đo: AUC – ROC

- **AUC** là diện tích dưới đường cong ROC.

$$TPR = \frac{TP}{TP + FN} \quad FPR = \frac{FP}{TN + FP}$$

- **Độ nhạy (Sensitivity) = TPR = Recall**
- **1 – Độ đặc hiệu (Specificity) = FPR**



Ma trận nhầm lẫn (Confusion Matrix)

- Nền tảng của mọi độ đo phân loại. Ví dụ: mô hình lọc rác thử trên 1.000 email.

	Dự đoán: RÁC	Dự đoán: KHÔNG RÁC
Thực tế: RÁC	TP = 90 (bắt đúng rác)	FN = 10 (lọt vào hộp thư)
Thực tế: KHÔNG RÁC	FP = 5 (gắn cờ nhầm)	TN = 895 (đúng, cho qua)

- **Accuracy** = $985/1000 = 98.5\%$

- **Precision** = $90/95 = 94.7\%$

- **Recall** = $90/100 = 90.0\%$

- **F1** = 92.3% (trung bình điều hòa)

⚠ **98.5% nghe hoàn hảo — nhưng 10 thư rác thật vẫn lọt qua!**

Khi nào dùng Precision / Recall / F1

- Đánh đổi: cải thiện chỉ số này thường làm giảm chỉ số kia.

A · Phát hiện ung thư

- Bỏ sót ca ung thư thật (FN)
= NGUY HIỂM TÍNH MẠNG
- → Ưu tiên **RECALL** cao
- “Bắt hết — kể cả vài báo động giả”

B · Lọc thư rác

- Chặn nhầm email quan trọng (FP) = RẤT TỐN KÉM
- → Ưu tiên **PRECISION** cao
- “Chỉ gán cờ khi rất chắc chắn là rác”

C · Gợi ý / Tìm kiếm

- Precision và Recall quan trọng ngang nhau
- → Dùng **F1-Score**
- Trung bình điều hòa — phạt lệch lớn


04

Huấn luyện, Overfitting & Kiểm định chéo

Training, Overfitting & Cross-Validation


Huấn luyện (Training)

- **Dữ liệu huấn luyện:** tập dữ liệu dùng để huấn luyện mô hình.
- **Tối ưu hóa:** cấu hình mô hình để đạt hiệu năng tốt nhất.



Suy luận (Inference)

- Sau khi mô hình đã được huấn luyện, ta đưa các ví dụ MỚI (chưa từng thấy) vào để nhận dự đoán.



Huấn luyện vs Suy luận

- Mục tiêu: hoạt động tốt trên dữ liệu CHƯA THẤY khi suy luận.

Huấn luyện (Training)

- Dùng dữ liệu có nhãn (người gán: “Xe đạp”, “Dâu tây”).
- So dự đoán với nhãn → tính Lỗi → cập nhật trọng số mô hình.

Suy luận (Inference)


- Dùng dữ liệu mới, chưa có nhãn.
- Mô hình (đã cố định trọng số) đưa ra dự đoán.

Khớp đường cong: Quá khớp vs Dưới khớp

- Mục tiêu: khớp một đường cong qua dữ liệu sao cho mô hình tổng quát hóa tốt.
- Hai thái cực cần tránh:
 - **Dưới khớp (Underfitting):** mô hình quá đơn giản.
 - **Quá khớp (Overfitting):** mô hình quá phức tạp, học cả “nhiều”.

Ví dụ: Dưới khớp (Underfitting)


Dưới khớp (Underfitting)



- Đường cong quá đơn giản → gọi là “dưới khớp”.
- Khớp KÉM trên dữ liệu huấn luyện.
- Khớp KÉM trên dữ liệu chưa thấy.
- *Mô hình bỏ sót các xu hướng hệ thống trong dữ liệu.*

Ví dụ: Quá khớp (Overfitting)

Quá khớp (Overfitting)



- Đường cong quá phức tạp → gọi là “quá khớp”.
- Khớp TỐT trên dữ liệu huấn luyện.
- Khớp KÉM trên dữ liệu chưa thấy.
- Mô hình quá nhạy, khớp luôn cả “nhiều” trong dữ liệu huấn luyện.

Quá khớp & Dưới khớp: Ví von sinh viên

DƯỚI KHỚP

- Học qua loa
- “Cứ chọn B cho mọi câu”
- Kém khi học X
- Kém khi thi mới X

KHỚP TỐT

- Học đúng cách
- “Mình hiểu bản chất”
- Tốt khi học ✓
- Tốt khi thi mới ✓

QUÁ KHỚP


- Học vẹt từng câu
- “Thuộc lòng trang 47, dòng 3”
- Hoàn hảo khi học ✓
- Kém khi thi mới X

Khắc phục — Dưới khớp: mô hình phức tạp hơn, thêm đặc trưng. **Quá khớp:** thêm dữ liệu, chính quy hóa (L1/L2), dropout, dừng sớm.


Bài toán khớp đường cong

- **Vấn đề:** dữ liệu chưa thấy không có sẵn lúc huấn luyện. Làm sao ước lượng hiệu năng? Đo trên chính dữ liệu huấn luyện dễ dẫn đến quá khớp.


Dưới khớp (Underfitting)



Khớp tốt (Good fit)



Quá khớp (Overfitting)



Giải pháp: Chia dữ liệu thành 2 tập

- **Tập huấn luyện (Training Set):** dữ liệu dùng trong quá trình huấn luyện.
- **Tập kiểm thử (Test Set):** dữ liệu dùng để đo hiệu năng, mô phỏng dữ liệu chưa thấy (KHÔNG dùng khi huấn luyện).

Tập huấn luyện (~70–80%)

Kiểm thử (~20–30%)

Tập kiểm thử KHÔNG được dùng trong quá trình huấn luyện

Chia Train – Test

- Đánh giá mô hình đã huấn luyện trên dữ liệu nó CHƯA “thấy” bao giờ, để mô phỏng suy luận thực tế.

Huấn luyện

- Dùng tập huấn luyện để cập nhật trọng số mô hình.
- *Mô hình “thấy” cả đặc trưng lẫn nhãn của dữ liệu này.*

Kiểm thử (Suy luận)

- Dùng tập kiểm thử để đo hiệu năng thực tế.
- *Mô phỏng dữ liệu “chưa thấy” mà mô hình sẽ gặp khi triển khai.*

Kiểm định chéo (K-fold Cross-Validation)

K-Fold (K=5)

Lần 1	Test	Train	Train	Train	Train
Lần 2	Train	Test	Train	Train	Train
Lần 3	Train	Train	Test	Train	Train
Lần 4	Train	Train	Train	Test	Train
Lần 5	Train	Train	Train	Train	Test

Mỗi điểm dữ liệu được dùng để kiểm thử đúng 1 lần → ước lượng đáng tin cậy hơn

Điểm: [91%, 89%, 93%, 88%, 90%] → Trung bình = 90.2% ± 1.7%

Vì sao K-Fold đáng tin hơn


- **Vấn đề với một lần chia train/test:** điểm số có thể “may” hoặc “rủi” tùy bạn chọn 30% nào để kiểm thử → chỉ có 1 con số, khó tin.
- **K-Fold (K=5):** chia 5 phần, luân phiên mỗi phần làm kiểm thử → thu được 5 điểm số.
- **Kết quả:** [91%, 89%, 93%, 88%, 90%] → Trung bình = 90.2% $\pm$ 1.7%
- *Mỗi điểm dữ liệu được dùng kiểm thử đúng 1 lần → ước lượng tin cậy hơn nhiều.*
Chuẩn thực hành: K = 5 hoặc 10.

05

Học sâu (Deep Learning)


Deep Learning

Học sâu (Deep Learning)



- Học sâu dùng mạng nơ-ron **NHIỀU LỚP** để tự động học các đặc trưng từ dữ liệu thô.
- **Khác biệt cốt lõi:** ML truyền thống cần con người thiết kế đặc trưng; Deep Learning tự học đặc trưng + phân loại trong cùng một mạng.
- *Là nền tảng cho thị giác máy tính, xử lý ngôn ngữ, và Generative AI hiện đại.*

Hiệu năng: Học máy vs Học sâu



- ML truyền thống bão hòa sớm khi dữ liệu tăng.
- **Deep Learning tiếp tục cải thiện khi có nhiều dữ liệu hơn.**
- *Yếu tố then chốt: dữ liệu lớn + GPU + kiến trúc phù hợp.*

Ví dụ ứng dụng Học sâu

- Nhận diện các loại cảm xúc và biểu cảm của con người.
- Nhận dạng người và động vật qua ảnh dựa trên dấu hiệu, đặc điểm riêng.
- Nhận dạng giọng nói của nhiều người và ghi nhớ.
- Chuyển video và giọng nói thành văn bản.
- Nhận diện cử chỉ đúng/sai, phân loại thư rác, phát hiện gian lận.


Học sâu trong sản phẩm thực tế

Ứng dụng	Kỹ thuật DL	Sản phẩm / Công ty
Nhận diện khuôn mặt	CNN	iPhone Face ID, Google Photos
Trợ lý giọng nói	RNN / Transformer	Siri, Google Assistant, Alexa
Phụ đề tự động	CNN + Seq2Seq	YouTube auto-captions
Chẩn đoán y khoa	CNN	DeepMind phát hiện bệnh mắt
Phát hiện gian lận	LSTM	PayPal, Visa cảnh báo thời gian thực
Gợi ý nội dung	Collaborative DNN	Netflix, Spotify, TikTok
Dịch máy	Transformer	Google Translate, DeepL
Sinh ảnh	Diffusion	DALL-E 3, Midjourney

Deep Learning hiện là động cơ của hầu hết sản phẩm AI bạn dùng hằng ngày

Học sâu: Trích đặc trưng + Phân loại

- **Đặc điểm chung:** mạng tự học trích xuất đặc trưng rồi phân loại — không cần thiết kể đặc trưng thủ công.



Mạng tích chập (CNN)

Xử lý ảnh: tự học cạnh → hình → bộ phận → vật thể.

Mạng hồi quy (RNN)

Xử lý dữ liệu chuỗi: mang “ký ức” qua từng bước.

LSTM / GRU

Cải tiến RNN: nhớ phụ thuộc xa hơn nhờ các cổng (gates).



06

Generative AI

Generative AI

Generative AI là gì?

- **Định nghĩa:** hệ thống AI tạo ra dữ liệu MỚI giống với dữ liệu huấn luyện.
- **Ứng dụng chính:** tổng hợp ảnh, sinh văn bản, soạn nhạc.
- **Cách hoạt động:**
 - **Đầu vào:** tập dữ liệu huấn luyện (ảnh, văn bản...).
 - **Huấn luyện:** học các mẫu và cấu trúc.
 - **Sinh đầu ra:** tạo nội dung mới, tương tự.
 - **Vòng phản hồi:** tinh chỉnh đầu ra dựa trên phản hồi người dùng.

Generative AI: Từ phân loại đến sáng tạo

AI truyền thống

- Đầu vào → Phân loại / Dự đoán
- “Email này là rác?” → Có/Không
- Học P(nhãn | dữ liệu)

Generative AI

- Câu lệnh → Tạo nội dung mới
- “Viết một email phản hồi chuyên nghiệp” 
- Học P(dữ liệu) → sinh dữ liệu mới

Cột mốc của Generative AI:

- 2014** GAN ra đời (Ian Goodfellow — bộ sinh vs bộ phân biệt)
- 2017** Kiến trúc Transformer — “Attention is All You Need” (Google)
- 2020** GPT-3 — 175 tỷ tham số, sinh văn bản trôi chảy (OpenAI)
- 2022** Stable Diffusion (mã nguồn mở), ChatGPT ra mắt
- 2023–2024** GPT-4, Gemini, Claude; Sora (văn bản → video), mô hình đa phương thức thời gian thực

Ứng dụng của Generative AI

- **Sáng tạo nội dung:** nghệ thuật, âm nhạc, văn học
- **Tăng cường dữ liệu:** làm giàu tập dữ liệu
- **Dữ liệu tổng hợp:** để huấn luyện mô hình AI
- **Thiết kế sản phẩm:** mô hình hóa & mô phỏng 3D
- **Marketing cá nhân hóa:** sinh nội dung động
- **Gợi ý sản phẩm:** đề xuất theo từng người
- **Phát hiện gian lận:** kịch bản gian lận tổng hợp
- **Dự báo tài chính & Chatbot / Trợ lý ảo:** phản hồi ngôn ngữ tự nhiên

Các kỹ thuật chính của GenAI

GAN

- **Cấu trúc:** Bộ sinh & Bộ phân biệt cạnh tranh
- **Ứng dụng:** Tổng hợp ảnh, deepfake
- **Thách thức:** Bất ổn khi huấn luyện, mode collapse

VAE

- **Cấu trúc:** Bộ mã hóa & Bộ giải mã
- **Ứng dụng:** Nén dữ liệu, phát hiện bất thường
- **Thách thức:** Ảnh sinh ra hơi mờ

Diffusion

- **Cấu trúc:** Khử nhiễu dần dữ liệu ngẫu nhiên
- **Ứng dụng:** Sinh ảnh độ phân giải cao, text→image
- **Thách thức:** Tốn tài nguyên tính toán

Transformer


- **Cấu trúc:** Cơ chế attention cho dữ liệu chuỗi
- **Ứng dụng:** Sinh văn bản (GPT, BERT), đa phương thức
- **Thách thức:** Mô hình lớn, chi phí huấn luyện cao

So sánh các kiến trúc GenAI

	GAN	VAE	Diffusion	Transformer
Ví von	Thợ làm giả vs Thám tử	Nén & tái dựng	Tạc tượng từ đá	Phiên dịch nhớ hoàn hảo
Cơ chế	2 mạng cạnh tranh	Mã hóa→ẩn→giải mã	Thêm nhiễu rồi khử	Attention toàn bộ đầu vào
Chất lượng	Sắc nét, thực	Hơi mờ	Rất cao	Sinh văn bản xuất sắc
Huấn luyện	Bất ổn	Ổn định	Chậm	Tốn bộ nhớ lớn
Nổi bật	StyleGAN, DeepFake	Phát hiện bất thường	DALL-E 3, Midjourney	GPT-4, Gemini, Claude

Hiện nay: Diffusion thống trị ảnh; Transformer thống trị văn bản & đa phương thức


Bộ tự mã hóa (AutoEncoder)



Nén đầu vào thành một “mã” (code) ở giữa rồi tái tạo lại — học biểu diễn cô đọng của dữ liệu. Ứng dụng: nén dữ liệu, phát hiện bất thường, tiền đề cho VAE.


Mạng đối sinh (GANs)

Hai mạng cạnh tranh nhau → ảnh sinh ngày càng giống thật



Bộ sinh (Generator) tạo ảnh giả; **Bộ phân biệt (Discriminator)** phân biệt thật/giả. Hai mạng “đấu” nhau đến khi ảnh giả gần như không phân biệt được với ảnh thật.

Mô hình khuếch tán (Diffusion)



- **Quá trình thuận:** thêm nhiễu dần cho đến khi ảnh thành nhiễu hoàn toàn.
- **Quá trình nghịch:** mô hình học cách KHỬ nhiễu từng bước để sinh ra ảnh mới mạch lạc, độ phân giải cao.

Transformer

- **Thành phần chính:**
 - **Encoder–Decoder:** xử lý chuỗi đầu vào và sinh đầu ra.
 - **Tự chú ý (Self-Attention):** tập trung đồng thời vào nhiều phần của chuỗi.
 - **Mã hóa vị trí (Positional Encoding):** thêm thông tin thứ tự.
 - **Mạng truyền thẳng:** biến đổi phi tuyến dữ liệu.
- **Ứng dụng:**
 - NLP (GPT, BERT, T5), dịch máy, sinh văn bản, xử lý ảnh (Vision Transformer).

Transformer: Tự chú ý bằng ngôn ngữ đời thường

- **Vấn đề:** đại từ mơ hồ trong câu dài.
- *“The trophy did not fit in the suitcase because it was too big.” — “it” chỉ trophy hay suitcase?*

Khi xử lý “it”, mô hình gán điểm chú ý:

trophy → 0.72 ◀ cao nhất

suitcase → 0.15

fit → 0.08 big → 0.05

Kết luận: “it” = trophy ✓

- **Hơn RNN ở đâu?**

- RNN phải nhớ qua nhiều bước và thường quên ngữ cảnh trước đó.
- Transformer nhìn **TẤT CẢ** từ cùng lúc — khoảng cách trong câu không còn là vấn đề.

Sinh ảnh từ văn bản (Text-to-Image)

- Người dùng nhập câu lệnh văn bản → mô hình sinh ra ảnh tương ứng.
- Mô hình tiêu biểu:
 - DALL-E 3 (OpenAI)
 - Stable Diffusion V2
 - Midjourney

Xu hướng trong GenAI

Mô hình đa phương thức

Tích hợp văn bản, ảnh, âm thanh, video trong một mô hình (GPT-4, Gemini). Ứng dụng: media tương tác, tìm kiếm đa phương thức.

AI tăng cường sáng tạo

AI là “đồng tác giả” trong nghệ thuật, âm nhạc, nội dung. Đặt lại câu hỏi về quyền tác giả.

Ứng dụng thời gian thực

GenAI trong game & môi trường ảo; sinh nội dung thời gian thực (đối thoại NPC, dựng thể giới động).

Khung AI có đạo đức

Xây dựng hướng dẫn cho AI an toàn, có trách nhiệm; nghiên cứu an toàn AI, công cụ kiểm toán.

07

Mô hình ngôn ngữ lớn (LLM) & Agent

Large Language Models & Agents

LLM – Mô hình ngôn ngữ lớn

- **Kiến trúc Transformer:**

- Cơ chế tự chú ý nắm bắt phụ thuộc trong văn bản; multi-head attention xử lý song song.

- **Mô hình Encoder–Decoder:**

- Encoder trích embedding ngữ cảnh; Decoder sinh chuỗi văn bản mạch lạc.

- **Tiền huấn luyện & Tinh chỉnh:**

- Tiền huấn luyện trên kho ngữ liệu khổng lồ (GPT, BERT); tinh chỉnh cho ứng dụng/lĩnh vực cụ thể.

LLM: Tiền huấn luyện, Tinh chỉnh & Mô hình dẫn đầu

Xây dựng LLM giống như đào tạo một bác sĩ:

TIỀN HUẤN LUYỆN

- Trường y (nhiều năm, tốn kém)
- Đọc mọi giáo trình → kiến thức tổng quát

TINH CHỈNH

- Nội trú (vài tuần, chuyên sâu)
- Thực hành ca bệnh thật → chuyên môn lĩnh vực

PROMPTING

- Khám hằng ngày (vài giây, miễn phí)
- Trả lời câu hỏi cụ thể → hoàn thành tác vụ

Một số LLM dẫn đầu hiện nay:

Mô hình	Bởi	Mở?	Thế mạnh
GPT-5o	OpenAI	Không	Đa năng, đa phương thức tốt nhất
Gemini 3.5	Google	Không	Ngữ cảnh dài, tìm kiếm thời gian thực
LLaMA 3.3	Meta	Có	Miễn phí dùng & tinh chỉnh
Qwen 3.5	Alibaba	Có	Tiếng Việt & Trung, lập trình
Claude 5	Anthropic	Không	Suy luận, an toàn, tài liệu dài

Ứng dụng của LLM → (Đa) Tác nhân (Agents)

- **Sinh văn bản:** viết nội dung tự động, sáng tác (tiểu thuyết, kịch bản).
- **AI hội thoại:** chatbot, trợ lý ảo, chăm sóc khách hàng.
- **Phân tích dữ liệu & NLP:** phân tích cảm xúc, trích chủ đề, tóm tắt & dịch.
- **Hỗ trợ lập trình:** sinh & gỡ lỗi mã nguồn, viết tài liệu & giải thích mã.
- **Đa phương thức:** kết hợp văn bản với ảnh/âm thanh; sinh ảnh từ văn bản, kịch bản video.
- **Multi-Agent:** nhiều tác nhân LLM phối hợp để giải quyết tác vụ phức tạp.